

Resumen Ejecutivo

PAUHelper es una aplicación web especializada en Generación Aumentada por Recuperación (RAG) diseñada para guiar a los estudiantes en el complejo y altamente regulado entorno de las pruebas de acceso a la universidad (PAU) en España. Más allá de su utilidad educativa, el proyecto sirve como demostración integral de un despliegue de IA a nivel empresarial, mostrando cómo conectar de forma segura potentes Modelos de Lenguaje (LLMs) con datos propietarios estrictamente validados.

El Problema de Negocio: Validación de Información de Alto Riesgo

Los estudiantes que preparan la PAU se enfrentan a un entorno de datos altamente fragmentado. El temario, los criterios de evaluación y los formatos de examen están estrictamente regulados, pero varían drásticamente dependiendo de la comunidad autónoma y la asignatura específica.

Las Fricciones y Riesgos:

- **Sobrecarga de Información:** Las directrices oficiales están enterradas en cientos de páginas de boletines en PDF dispersos por varios portales gubernamentales.
- **Alucinación de la IA:** Las herramientas de IA genéricas (como ChatGPT estándar) a menudo proporcionan respuestas "promedio" que no se alinean con los criterios regionales precisos, poniendo en riesgo la nota del estudiante.
- **Falta de Trazabilidad:** Cuando una IA proporciona una pauta de estudio, actualmente el usuario no tiene forma de verificar de qué mandato oficial proviene esa información.

La Solución Propuesta: Inteligencia Sensible al Contexto

PAUHelper resuelve estos problemas actuando como un asistente de estudio hiperespecializado y altamente fiable. En lugar de depender del conocimiento paramétrico general de la IA, el sistema obliga al modelo a leer únicamente documentos oficiales verificados antes de responder.

La Experiencia del Usuario:

- El estudiante selecciona su comunidad autónoma, asignatura y preferencias de idioma.
- Realiza una pregunta o sube una imagen de un problema con el que tiene dificultades.
- El sistema recupera instantáneamente los párrafos exactos del temario oficial que coinciden con la consulta, los lee y devuelve una respuesta precisa basada estrictamente en el currículo oficial.
- Crucialmente, proporciona las citas exactas de los documentos fuente, estableciendo una confianza absoluta.

Arquitectura del Sistema y Flujo de Datos

Para garantizar cero alucinaciones, PAUHelper separa la búsqueda de información de la generación de texto. Esta orquestación es invisible para el usuario no técnico, pero garantiza la integridad total de los datos.



1 Petición del Usuario y Manejo de Entrada

El estudiante selecciona su configuración (Región, Asignatura, Idioma) e introduce una consulta de texto o sube una imagen. El frontend empaqueta esto de forma segura y lo envía al backend a través de una conexión encriptada.

2 Orquestador de IA (LangGraph)

El backend actúa como un controlador de tráfico inteligente. Procesa la consulta, identifica exactamente qué busca el estudiante y prepara una estrategia de búsqueda adaptada específicamente a la región y asignatura seleccionadas.

3 Recuperación de Datos y Memoria

El sistema consulta simultáneamente una base de datos vectorial especializada para extraer los párrafos más relevantes de los documentos oficiales, y revisa una caché de Redis para recordar las preguntas previas del usuario, asegurando una conversación natural y continua.

4 Generación del Modelo de Lenguaje

Los documentos extraídos, el historial de conversación y la pregunta del usuario se agrupan y se envían al LLM (como Google Gemini). El modelo recibe instrucciones estrictas: *"Solo puedes responder utilizando los documentos proporcionados."*

Valor Comercial Intersectorial

Aunque PAUHelper está optimizado para el sector educativo, la arquitectura subyacente — Generación Aumentada por Recuperación— resuelve uno de los desafíos más críticos de la empresa moderna: **hacer que grandes cantidades de datos propietarios no estructurados se puedan consultar instantáneamente sin comprometer la precisión.**

Eliminación de Silos de Información

Los trabajadores del conocimiento dedican aproximadamente el 20% de su jornada a buscar información interna. Al centralizar los datos en una base de datos vectorial semántica, los empleados pueden consultar en lenguaje natural y recibir respuestas sintetizadas al instante, reduciendo drásticamente el tiempo de investigación y la fricción operativa.

Mitigación de Alucinaciones de la IA

Los LLMs estándar están entrenados para generar texto que suene plausible, lo que puede provocar errores costosos en entornos empresariales. Como esta arquitectura está restringida a utilizar únicamente documentos internos proporcionados, el riesgo de hechos "inventados" se elimina virtualmente, fomentando la confianza empresarial.

Aplicación Paralela: Sector Legal (Legal Tech)

Al igual que un estudiante consulta normativas regionales, los abogados pueden usar esta arquitectura exacta para consultar jurisprudencia, carteras de contratos y directrices de cumplimiento. El sistema recupera cláusulas relevantes y cita explícitamente la página específica del contrato, acelerando la diligencia debida.

Aplicación Paralela: Soporte al Cliente

Los equipos de soporte corporativo pueden desplegar esto como un "Copiloto para Agentes". En lugar de temarios educativos, la base de datos se carga con manuales técnicos internos y tickets de soporte pasados, permitiendo a los agentes de nivel 1 resolver problemas complejos de clientes instantáneamente con datos precisos y validados.

El Efecto "Volante" de Datos (Data Flywheel)

A medida que los usuarios interactúan con el sistema, la aplicación rastrea de forma inherente qué

Stack Tecnológico y Escalabilidad

Para lograr una fiabilidad de nivel empresarial, PAUHelper está construido sobre un stack tecnológico moderno y nativo de la nube. Está diseñado para ser altamente escalable, rentable y fácilmente mantenible por un equipo de ingeniería reducido.

Frontend: React y Vite

Ofrece una experiencia de Aplicación de Página Única (SPA) fluida directamente en el navegador. Maneja estados complejos (como el historial del chat y la subida dinámica de imágenes) sin problemas, asegurando que los usuarios no experimenten ninguna fricción, independientemente del dispositivo que utilicen.

Backend: FastAPI y LangGraph

FastAPI proporciona una puerta de enlace API asíncrona de alto rendimiento. LangGraph maneja la compleja máquina de estados del agente de IA, enrutando tareas explícitamente (recuperar, generar, resumir memoria) para asegurar que la IA siga un flujo lógico rígido y predecible.

Base de Datos: Qdrant Vector DB

Las bases de datos tradicionales buscan por coincidencia de palabras clave. Qdrant busca por "significado" matemático. Si un usuario pregunta sobre "reglas de redacción", encontrará documentos que hablen sobre "pautas de sintaxis", asegurando una recuperación de alta calidad incluso con fraseo variado.

Infraestructura: Google Cloud y Terraform

Todo el entorno está codificado mediante Terraform (Infraestructura como Código). Esto asegura que la infraestructura sea perfectamente reproducible, autodescriptiva y auditable, eliminando por completo los errores de configuración manual de servidores.

Seguridad y Eficiencia de Costes (Escalabilidad a Cero)

Aislamiento Estricto de Red: La base de datos central que contiene documentos propietarios se despliega en una Nube Privada Virtual (VPC) sin direcciones IP públicas. Solo puede ser accedida internamente por microservicios autorizados.

Computación Elástica: Alojada en Google Cloud Run, la aplicación utiliza una arquitectura *serverless* (sin servidor). Durante las horas de inactividad (ej. 3:00 AM), la aplicación se reduce a cero, no costando nada. Durante las semanas inmediatamente anteriores a los exámenes finales, el servicio puede desplegar instantáneamente cientos de clones del contenedor para manejar miles de estudiantes concurrentes sin degradación de la velocidad.